

Pontifícia Universidade Católica do Rio de Janeiro

Curso: Ciência de Dados – PUC RIO

MVP – Sprint Engenharia de Dados

Maria Eduarda Battaglia Pedreira Fernandes

Prof. Dr. Sérgio Lifschitz

Abril de 2025

Sumário

MVP – Sprint Engenharia de Dados.....	1
1. Introdução	3
2. Objetivo do Trabalho	3
3. Coleta dos Dados.....	4
4. Modelagem e Catálogo de Dados	6
Camada Bronze	6
Camada Silver.....	8
Camada Gold	9
5. Análise	11
a) Qualidade dos Dados.....	11
b) Solução do Problema.....	11
6. Meu repositório GitHub.....	17
7. Autoavaliação	17

1. Introdução

O presente trabalho visa aplicar os conhecimentos de engenharia de dados e tem como objetivo a construção de um pipeline de dados em nuvem utilizando exclusivamente a linguagem SQL na plataforma Databricks Community Edition. O conjunto de dados representa informações reais de consumo musical no Spotify ao longo de 2024.

2. Objetivo do Trabalho

O objetivo deste trabalho é aplicar uma arquitetura de pipeline de dados em nuvem utilizando a plataforma Databricks e a linguagem SQL, a fim de responder perguntas de negócio reais com base no conjunto de dados de streaming global do Spotify em 2024. Este projeto busca responder:

Este MVP visa responder a perguntas reais de negócio a partir da análise do dataset:

- **QUAIS OS ARTISTAS MAIS POPULARES GLOBALMENTE?**
- **QUAL O GÊNERO MUSICAL MAIS DOMINANTE?**
- **QUAIS PAÍSES MAIS CONSOMEM MÚSICAS?**
- **QUAL A MÉDIA DE STREAMS POR MÚSICA/ARTISTA?**
- **EXISTE DIFERENÇA DE CONSUMO ENTRE GÊNEROS?**

3. Coleta dos Dados


A base de dados utilizada foi obtida na plataforma pública **Kaggle**, através do dataset "**Spotify 2024 Global Streaming Data**". A coleta foi realizada manualmente, por meio do *download* do arquivo **.csv**, que foi posteriormente carreguei na plataforma *Databricks Community Edition*.

O conjunto de dados contém informações como país, artista, gênero musical, número de execuções (*streams*), plataforma, duração média de execução, entre outros.

- Fonte: **Kaggle** (<https://www.kaggle.com/datasets>)
- Dataset: Spotify 2024 Global Streaming Data
- Formato: CSV
- Plataforma utilizada: *Databricks Community Edition*
- Licença: License Apache 2.0

A **Apache License 2.0** é uma licença de software livre e permissiva criada pela *Apache Software Foundation*. Ela permite que outras pessoas usem, modifiquem e distribuam o *software* de forma livre, inclusive para fins acadêmicos.

- Autor: Atharva Soundankar






Image: CSV




Image: Preview table Bronze


4. Modelagem e Catálogo de Dados

Foi adotada a modelagem em formato **flat**, estruturada por camadas (Bronze, Silver e Gold). As camadas foram desenvolvidas de forma incremental, refletindo o processo de transformação dos dados brutos até a geração de métricas finais.

O PIPELINE DE CARGA IMPLEMENTADO COM BASE NA ARQUITETURA DE CAMADAS:

Camada Bronze

Nesta etapa, os dados foram carregados diretamente a partir do arquivo .csv, sem nenhuma transformação. A tabela foi criada no Databricks utilizando o comando CREATE TABLE com opção USING CSV, mantendo os nomes originais das colunas.



The screenshot shows the Databricks workspace interface. The top navigation bar includes 'New', 'Workspace', 'Recents', 'Search', 'Catalog', 'Workflows', 'Compute', 'Machine Learning', and 'Experiments'. The main workspace area displays a SQL query: `SELECT * FROM bronze_spotify_2024 LIMIT 10;`. Below the query, a table of 10 rows is shown, representing Spotify data. The table columns are Country, Artist, Album, Genre, Release Year, and 1.2 Monthly Listeners (Millio...).

	Country	Artist	Album	Genre	Release Year	1.2 Monthly Listeners (Millio
1	Germany	Taylor Swift	1989 (Taylor's Version)	K-pop	2019	
2	Brazil	The Weeknd	After Hours	R&B	2022	
3	United States	Post Malone	Austin	Reggaeton	2023	
4	Italy	Ed Sheeran	Autumn Variations	K-pop	2018	
5	Italy	Ed Sheeran	Autumn Variations	R&B	2023	
6	Sweden	Billie Eilish	Happier Than Ever	Indie	2019	
7	France	Bad Bunny	Nadie Sabe Lo Que Va a Pasar Mañana	Rock	2021	
8	France	Doja Cat	Scarlet	Pop	2020	
9	Sweden	Bad Bunny	Nadie Sabe Lo Que Va a Pasar Mañana	K-pop	2019	
10						

10 rows | 0.51s runtime Refreshed now

Catálogo de Dados – Camada Bronze

Tabela: bronze_spotify_2024

Base original, bruta, sem transformações. Importada diretamente do arquivo .csv do Kaggle.

Coluna	Tipo	Descrição	Pode ser nulo?	Observações
País	CORDA	País do ranking de streams	Tentar	Inconsistências possíveis
Artista	CORDA	Nome do artista	Tentar	Texto livre
Álbum	CORDA	Nome do álbum ou faixa	Tentar	Texto livre
Gênero	CORDA	Gênero musical	Tentar	Categórico
Ano de lançamento	INT	De novo	Tentar	Não utilizado no MVP
Lista Mensal	FLUTUADOR	Ouvintes mensais em milhões	Tentar	Não utilizado no MVP
Total de transmissões (milhões)	FLUTUADOR	Total de streams em milhões	Tentar	Campo usado na Silver
Total	FLUTUADOR	Total de horas ouvidas	Tentar	Não utilizado no
Duração média da transmissão (min)	FLUTUADOR	Duração média de reprodução	Tentar	Não utilizado no MVP
Tipo de plataforma	CORDA	Plataforma (Spotify, Apple Music...)	Tentar	Renomeado depois na Silver
Últimos 30 streams	FLUTUADOR	Streams nos últimos 30 dias	Tentar	Não utilizado no MVP
Taxa de omissão (%)	FLUTUADOR	Taxa de pulo da faixa	Tentar	Não utilizado no MVP

Linhagem:


- Fonte: Kaggle – Conjunto de dados de streaming global do Spotify 2024
- Técnica: Upload manual via interface do Databricks
- Status: Dados brutos, não tratados

Camada Silver

Transformação: renomear colunas, conversão de valores

Os dados foram tratados nesta etapa. Foram realizados:

- Renomeação de colunas (ex: Album → track_name)
- Conversão de tipos (FLOAT → BIGINT)
- Multiplicação do campo Total Streams (Millions) por 1.000.000
- Eliminação de registros com valores nulos nos campos essenciais
- Uniformização dos dados para facilitar as agregações na camada seguinte



The screenshot shows the Databricks interface with a workspace titled 'MVP - PUC - ENG DADOS - DUDABPF'. A SQL query is executed: `SELECT * FROM silver_spotify_2024 LIMIT 20;`. The results are displayed in a table with 6 columns: track_name, artist, genre, country, streams, and platform_type. The table contains 15 rows of data, including tracks like '1989 (Taylor's Version)' by Taylor Swift and 'After Hours' by The Weeknd. The interface also shows a sidebar with navigation options like Workspace, Recents, Search, Catalog, Workflows, and Compute.

track_name	artist	genre	country	streams	platform_type
1989 (Taylor's Version)	Taylor Swift	K-pop	Germany	3695530000	Free
After Hours	The Weeknd	R&B	Brazil	2828160000	Premium
Austin	Post Malone	Reggaeton	United States	1425460000	Free
Autumn Variations	Ed Sheeran	K-pop	Italy	2704330000	Premium
Autumn Variations	Ed Sheeran	R&B	Italy	3323250000	Free
Happier Than Ever	Billie Eilish	Indie	Sweden	1087060000	Free
Nadie Sabe Lo Que Va a Pasar Mañana	Bad Bunny	Rock	France	4630690000	Premium
Scarlet	Doja Cat	Pop	France	377630000	Premium
Nadie Sabe Lo Que Va a Pasar Mañana	Bad Bunny	K-pop	Sweden	2828770000	Premium
Eternal Sunshine	Ariana Grande	Rock	United Kingdom	4312460000	Premium
Future Nostalgia	Dua Lipa	Jazz	Argentina	4310860000	Premium
BORN PINK	BLACKPINK	Reggaeton	South Korea	3624360000	Free
Scarlet	Doja Cat	Jazz	South Korea	1900670000	Free
SOS	SZA	Indie	Germany	1242310000	Premium
Austin	Post Malone	Reggaeton	South Africa	4736900000	Premium

Catálogo de Dados – Camada Silver

Tabela: silver_spotify_2024

Dados já tratados: colunas renomeadas, dados nulos removidos, valores convertidos.

Coluna	Tipo	Descrição	Domínio esperado	Pode ser nulo?	Observações
nome_da_faixa	CORDA	Nome da música	Texto livre	Não	Renomeado de "Album"
artista	CORDA	Nome do artista	Texto livre	Não	Renomeado de "Artist"
gênero	CORDA	Gênero musical	Ex: pop, hip hop, rock	Não	Renomeado de "Genre"
país	CORDA	País do ranking	Texto livre (nomes de país)	Não	Renomeado de "Country"
córrgos	BIGINT	Total de streams (valor real)	Mín: 0 /	Não	Convertido de "Total Streams (
tipo_de_plataforma	CORDA	Plataforma usada	Spotify, Apple Music...	Tentar	Renomeado de "Tipo de Plataforma"

Linhagem:


- Fonte: Camada Bronze
- Técnica:
 - Remoção de nulos em campos essenciais
 - Renomeação de colunas para nomes padronizados
 - Conversão de streams de milhões para número real
 - Conversão de tipos para análise agregada

Camada Gold

Esta etapa corresponde à construção das métricas de negócio. Foram gerados valores agregados por artista, gênero e país. Foram calculados:

- Número total de músicas diferentes (COUNT DISTINCT)
- Soma de riachos (SUM)
- Média de streams por música (AVG)

Essas informações foram persistidas em uma tabela final chamada **gold_spotify_metrics**.



The screenshot shows the Databricks interface with a workspace named 'MVP - PUC - ENG DADOS - DUDABPF'. A SQL query is executed, showing 0 rows and 9.91s runtime. The query is: `SELECT * FROM gold_spotify_metrics LIMIT 20;`. Below the query, a table view displays 20 rows of data. The table has 7 columns: `artist`, `genre`, `country`, `total_musicas`, `total_streams`, and `media_streams_por_musica`. The data includes artists like BTS, Billie Eilish, Bad Bunny, Karol G, The Weeknd, Dua Lipa, Taylor Swift, and Aniana Grande.

	artist	genre	country	total_musicas	total_streams	media_streams_por_musica
1	BTS	R&B	South Korea	1	4664930000	2332465000
2	Billie Eilish	Hip Hop	Netherlands	1	1274010000	637005000
3	Bad Bunny	Indie	Netherlands	1	1411160000	1411160000
4	Karol G	EDM	Russia	1	2686280000	2686280000
5	The Weeknd	EDM	Spain	1	543040000	543040000
6	Dua Lipa	R&B	Russia	1	5195940000	2597970000
7	Billie Eilish	Jazz	Netherlands	1	2140810000	2140810000
8	Taylor Swift	K-pop	Brazil	1	2766580000	2766580000
9	The Weeknd	Hip Hop	South Africa	1	3979360000	3979360000
10	BTS	Pop	Spain	1	3902640000	3902640000
11	SZA	Hip Hop	Brazil	1	375130000	375130000
12	Dua Lipa	Rock	Italy	1	4416070000	4416070000
13	Bad Bunny	Indie	Sweden	1	450020000	450020000
14	The Weeknd	Rock	Turkey	1	2477660000	2477660000
15	Aniana Grande	EDM	India	1	2534020000	2534020000

Catálogo de Dados – Camada GOLD

Tabela: gold_spotify_metrics

Tabela final de métricas geradas para análise.

Coluna	Tipo	Descrição	Domínio Esperado	Pode ser nulo?	Observações
artista	CORDA	Nome do artista	Texto livre	Não	Dados categóricos
gênero	CORDA	Gênero musical	Exemplo: pop	Não	Dados categóricos
país	CORDA	País de referência da análise	Ex: Brasil, EUA, Argentina	Não	Dados categóricos
total_musicas_	INT	Quantidade de músicas distintas por artista	Meu_	Não	Numérico discreto
total_streams_	BIGINT	Total de streams acumulados	Mín: 1000 / Máx: bilhões	Não	Numérico contínuo
fluxos_de_mídia_por_música	FLUTUADOR	Média de streams por música	Mín: 0 / Máx: bilhões	Não	Calculado com 2 casas decimais

Linhagem:

- Fonte: Camada Silver
- Técnica:
 - Agregações via GROUP BY
 - Cálculo de soma, contagem e média
 - Persistência em tabela final para análise de negócio

5. Análise

a) Qualidade dos Dados

Foi realizada uma análise de qualidade dos dados logo após a construção da camada Silver, com o objetivo de garantir que os atributos utilizados na camada Gold estivessem livres de inconsistências e prontos para agregações e análises estatísticas.

O processo de validação envolveu:

- Verificação da existência de valores nulos nas colunas principais: *track_name*, *streams*, *artist*, *genre* e *country*
- Conversão correta da coluna *Total Streams (Millions)* para valores absolutos (multiplicação por 1.000.000), garantindo integridade numérica.
- Renomeação de colunas para padronização e legibilidade do modelo.
- Checagem de tipos de dados para garantir compatibilidade com funções de agregação (SUM, AVG, COUNT).

Resultado: Nenhuma inconsistência crítica foi identificada nos dados utilizados.


As colunas categóricas foram padronizadas e os dados numéricos foram convertidos corretamente. A análise demonstrou que o dataset, apesar de originado de dados brutos (Bronze), foi tratado adequadamente na Silver para gerar uma Gold confiável.

b) Solução do Problema

A camada Gold foi projetada para responder às perguntas de negócio definidas na seção de Objetivo, com base em dados reais de consumo musical global do Spotify. Foram utilizadas agregações SQL (via GROUP BY) para responder de forma técnica e objetiva às perguntas.

Pergunta 1: Quais são os artistas mais populares globalmente com base no total de streams?

Resposta: Criada a **tabela top10_artistas**, que ordena os artistas pelo volume total de streams somados.




MVP - PUC - ENG DADOS - DUDABPF

Plataforma A

community.cloud.databricks.com/editor/notebooks/179939443563957o=1723713586173406

Pergunta 2: Qual gênero musical teve mais destaque em 2024?

Resposta: **Tabela gêneros_populares**, que agrupa e ordena os gêneros musicais pelo total de *streams*.




The screenshot shows the same Databricks notebook interface. The main content area displays the same SQL query: `SELECT * FROM generos_populares;`. Below the query, a table titled 'Visualization 1' is shown. The table has two columns: 'genre' and 'total_streams'. The data is sorted by 'total_streams' in descending order. The table is refreshed 53 minutes ago.

genre	total_streams
Classical	197276790000
Rock	148418929998
Indie	133083470000
K-pop	132513200000
EDM	125801690000
Pop	118219069998
R&B	113951780000
Hip Hop	111958510000
Reggaeton	105789800000
Jazz	103563780000

Pergunta 3: Quais países possuem os maiores consumos de músicas em termos de número de streams?

Resposta: A tabela **países_com_mais_streams** soma os *streams* por país, revelando os países com maior volume de reprodução.




The screenshot shows the Databricks workspace with a SQL query executed. The query is: `SELECT * FROM países_com_mais_streams;`. Below the query, a table titled 'Table' displays the results. The table has 2 columns: 'country' and 'total_streams'. The data is as follows:

country	total_streams
Sweden	93449760000
South Korea	87594209999
South Africa	87431730000
Brazil	77383149999
Italy	75671880000
Russia	69990429999
Mexico	67240710000
France	66305820000
Argentina	65821910000
Netherlands	61741169999
Canada	61235620000
India	60223530000
Spain	58007330000
Japan	57581130000
Indonesia	56831990000

Pergunta 4: Qual a média de *streams* por música por artista?

Resposta: Através da tabela **media_streams_por_artista**, é possível observar quais artistas têm a média mais alta de consumo por faixa.



0 rows | 4.55s runtime


media_streams_por_artista

artist	media_streams
Dua Lipa	3008270000
Ariana Grande	2869031111.11
BTS	2824687954.52
BLACKPINK	2763213243.22
Bad Bunny	2655404000
Billie Eilish	2650803548.39
Doja Cat	2649865588.24
Drake	2611255161.29
The Weeknd	2523978000
Ed Sheeran	2510267142.83

10 rows | 1.11s runtime

Pergunta 5: Há diferença significativa entre gêneros musicais quanto ao número de *streams*?

Resposta: A tabela **media_streams_por_genero** mostra a média de *streams* por gênero, permitindo comparações diretas entre estilos.



The screenshot shows the same Databricks notebook with the table view selected. The table has 10 rows and 2 columns: 'genre' and 'media_streams'. The data is as follows:

genre	media_streams
R&B	2779311707.32
K-pop	2760691666.67
Classical	273995416.67
Pop	2686797499.95
Indie	2661669400
Rock	2558947068.93
EDM	2466699803.92
Jazz	2408460000
Reggaeton	2404313636.36
Hip Hop	2284867551.02

A análise mostrou que determinados gêneros dominam o cenário global (como pop e hip hop), e artistas de alto impacto concentram grande parte das execuções. Países como Estados Unidos e Brasil apresentaram volume expressivo de consumo. A métrica de média por faixa também evidenciou a relevância de artistas que, apesar de menos faixas, apresentam alta performance por música. Essa análise de dados real reflete o comportamento de consumo e pode ser útil para decisões de marketing musical e lançamento de conteúdo.

6. Meu repositório GitHub

O link a seguir encaminhará direto para o meu repositório no GitHub onde terá acesso ao meu MVP completo com todas as evidências, código e readme.

<https://github.com/dudabattaglia/MVPdudabpf>

7. Autoavaliação

Reflexão sobre o MVP

Durante a execução deste MVP, pude aplicar na prática os conceitos de arquitetura de dados, pipeline ETL e análise SQL. Utilizando o Databricks Community Edition, aprendi a organizar dados em camadas, tratar inconsistências, transformar dados em informações relevantes e criar métricas para responder a perguntas de negócio.

As maiores dificuldades surgiram na adaptação do schema original e na manutenção da compatibilidade de tipos para operações de agregação. Com estudo e testes, consegui superar esses obstáculos e entregar um projeto completo e funcional.

Escolhi trabalhar com uma base de dados do Kaggle por ser de fácil compreensão e adequada aos objetivos do projeto. Considero que alcancei os resultados propostos, especialmente por estar iniciando na área. O processo foi desafiador, mas extremamente enriquecedor. Aprofundei meus conhecimentos em SQL,

Spark e ETL, além de conhecer melhor o Databricks Community Edition — uma ferramenta acessível e eficaz para a prática em engenharia de dados.

Trabalhos Futuros

Este MVP é apenas um ponto de partida. Algumas ideias para evolução incluem:

- Explorar modelos em estrela ou snowflake para organização dos dados, embora ainda não me sinta totalmente segura para implementá-los.
 - Ampliar a base de dados com informações públicas, como dados demográficos dos municípios, para enriquecer a análise de público-alvo das empresas.
 - Adotar ferramentas de visualização mais avançadas e automação na carga de dados.
-

Agradecimentos

Agradeço primeiramente a Deus, pela vida e pela graça diária. Agradeço também:

À PUC-Rio, aos professores e instrutores, pela oportunidade de cursar essa pós-graduação que tanto tem me agregado;

À minha família, pelo apoio e compreensão nos momentos de intensa dedicação;

Aos colegas de turma pelas trocas de ideias que contribuíram demais para o desenvolvimento deste trabalho.